


# Perceptrón Multicapa



Sistemas de Inteligencia Artificial

Primer Cuatrimestre 2023



Rodrigo Ramele  
Eugenia Piñeiro  
Alan Pierri  
Santiago Reyes  
Marina Fuster  
Luciano Bianchi



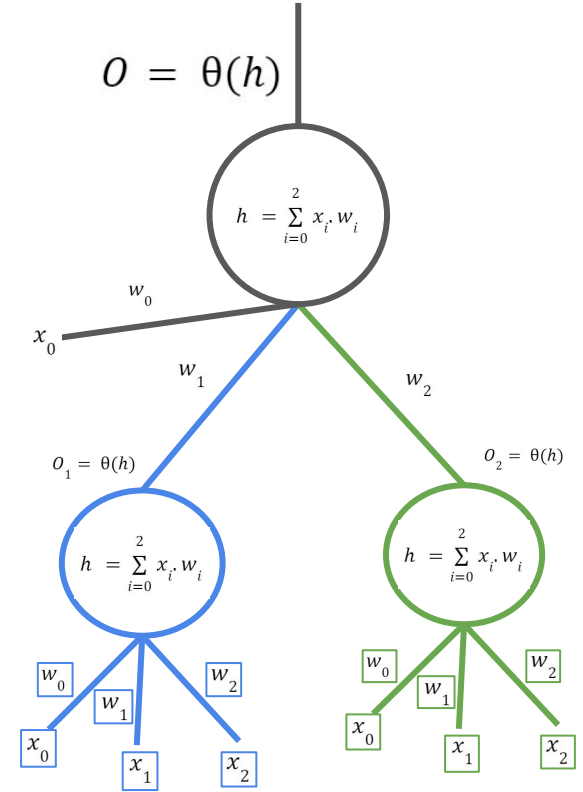

$\theta = \text{función activación escalón}$



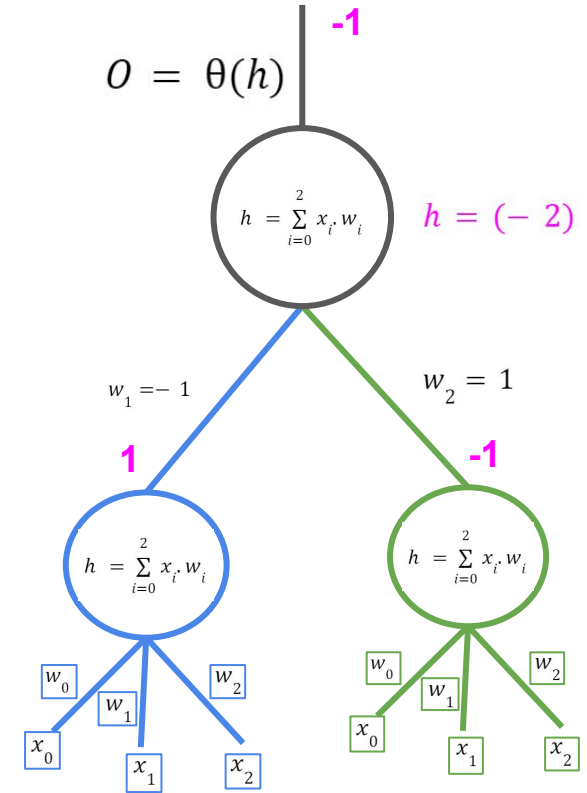

$\theta = \text{función activación escalón}$





$\theta = \text{función activación escalón}$





$\theta = \text{función activación escalón}$



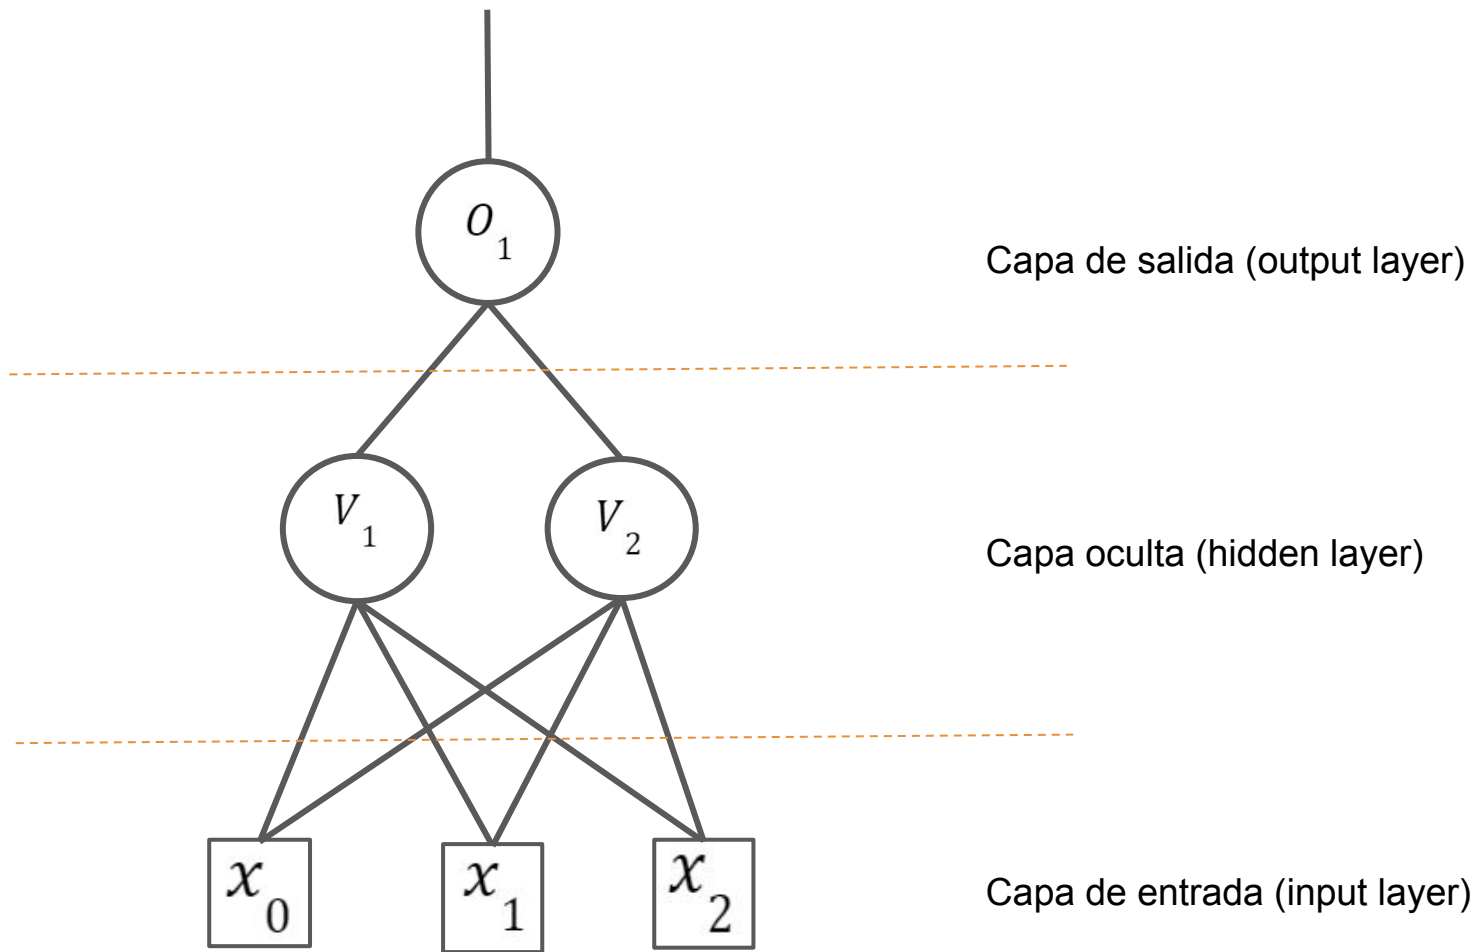
$\theta = \text{función activación escalón}$



$\theta = \text{función activación escalón}$








$M = \text{cantidad capas}$

## PERCEPTRÓN MULTICAPA



# NOTACIÓN


Índice	Descripción
i	índice de la neurona de la capa de salida (o siguiente)
j	índice de la neurona de la capa intermedia
k	índice de la neurona de entrada o de la capa anterior
m	índice de la capa intermedia
p	cantidad datos
$\mu$	dato en particular

$w_{jk}^m$  = pesos sinápticos

$V_j^m$  = neurona de capa intermedia

$W_{ij}$  = pesos sináticos de la última capa

$O_i$  = neurona de capa de salida



# NOTACIÓN

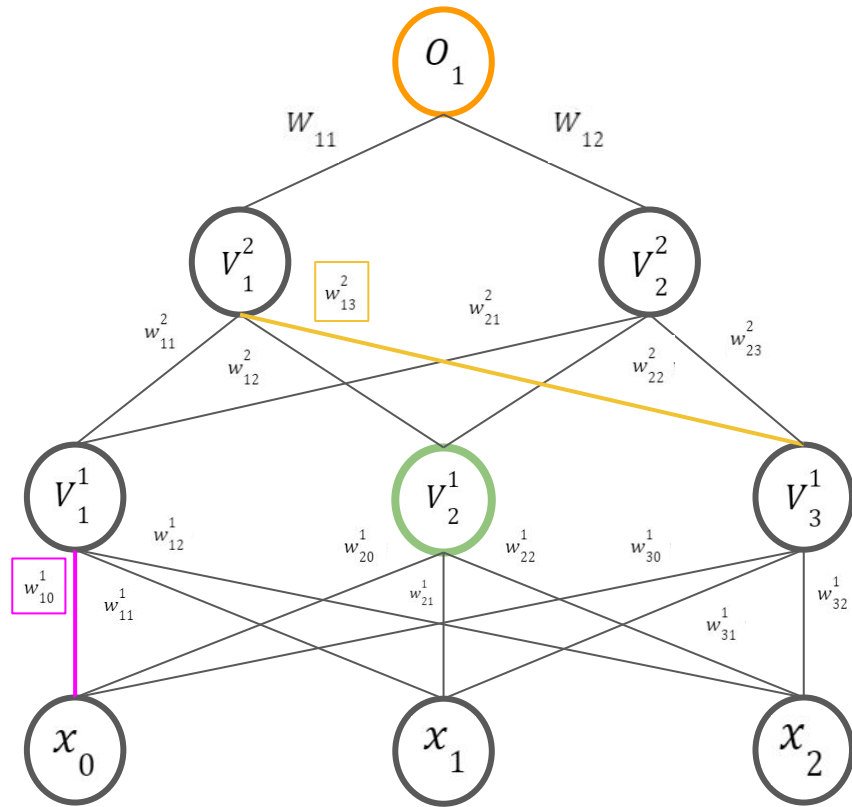
Índice	Descripción
i	índice de la neurona de la capa de salida
j	índice de la neurona de la capa intermedia
k	índice de la neurona de entrada o de la capa anterior
m	índice de la capa intermedia
p	cantidad datos
$\mu$	dato en particular

$w_{jk}^m$  = pesos sinápticos

$V_j^m$  = neurona de capa intermedia

$W_{ij}$  = pesos sinápticos de la última capa

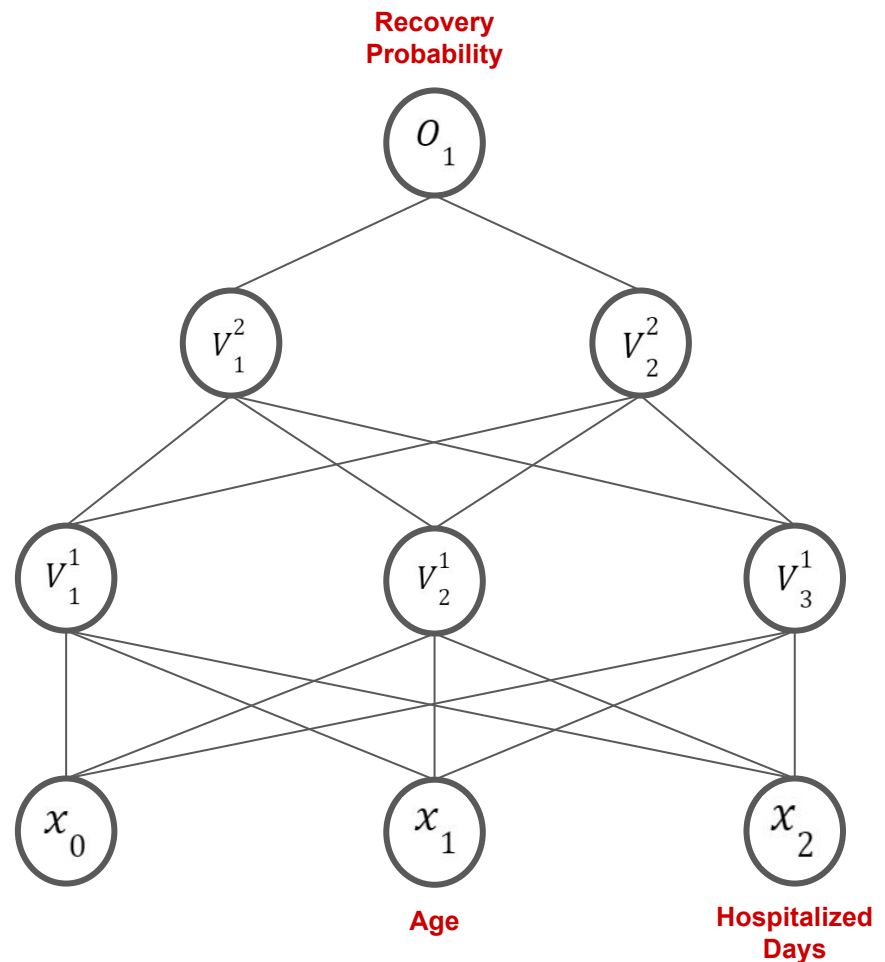

$O_i$  = neurona de capa de salida







	PERCEPTRÓN SIMPLE	PERCEPTRÓN MULTICAPA
Proceso para obtener la salida de la neurona (“predecir”)	$O = \theta\left(\sum_{i=0}^n x_i \cdot w_i\right)$	?
Función de error con respecto a la salida esperada	$E(O) = \frac{1}{2} \sum_{\mu=1}^p (\zeta^{\mu} - O^{\mu})^2$	?
Proceso de “aprendizaje” para ajustar los pesos	$w^{nuevo} = w^{anterior} + \Delta w$ $\Delta w = -\eta \frac{\partial E}{\partial w}$	?

# CALCULAR LA SALIDA DE LA NEURONA




# CALCULAR LA SALIDA DE LA NEURONA

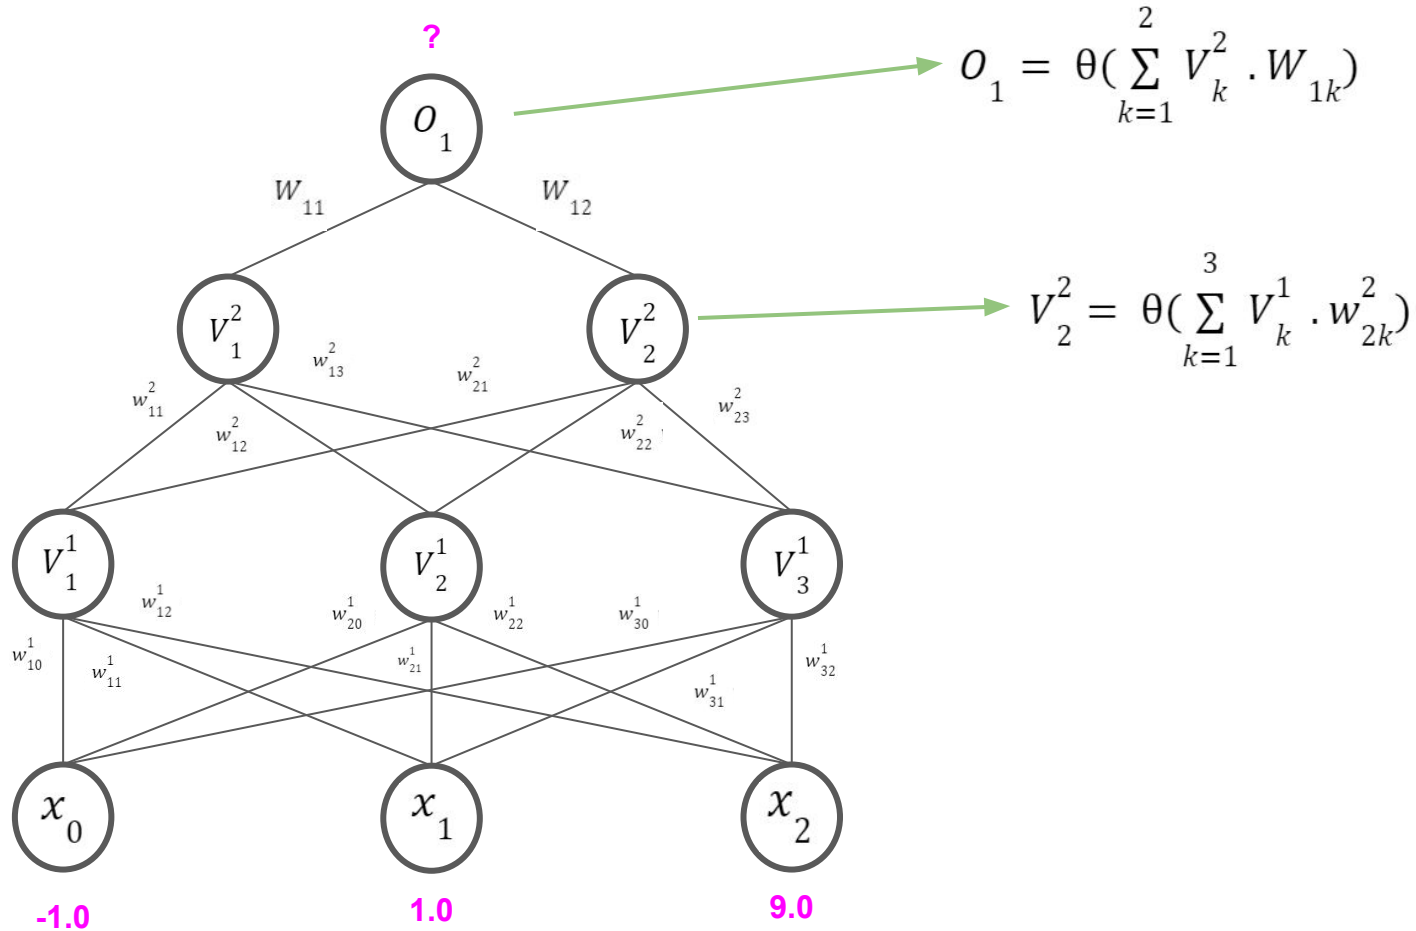





$$\mu = 18$$




$$\mu = 18$$



$$\mu = 18$$



$$\mu = 18$$



Propagación  
hacia adelante  
(forward  
propagation)

## PROPAGACIÓN HACIA ADELANTE (FORWARD PROPAGATION)

Salida de la neurona:

$$O_i = \theta\left(\sum_{k=1}^{M-1} V_k^{M-1} \cdot W_{ik}\right)$$

Salida de la neurona de una capa intermedia:


$$V_j^m = \theta\left(\sum_{k=1} V_k^{m-1} \cdot w_{jk}^m\right) \quad m = 2 \dots M - 1$$

Salida de la neurona de la primera capa intermedia:

$$V_j^1 = \theta\left(\sum_{k=1} x_k^\mu \cdot w_{jk}^1\right)$$

	PERCEPTRÓN SIMPLE	PERCEPTRÓN MULTICAPA
Proceso para obtener la salida de la neurona (“predecir”)	$O = \theta\left(\sum_{i=0}^n x_i \cdot w_i\right)$	$V_j^m = \theta\left(\sum_{k=1} V_k^{m-1} \cdot w_{jk}^m\right)$ $m = 1 \dots M \quad (O_i = V_i^M, x_i = V_i^0)$
Función de costo (medir error con respecto a la salida esperada)	$E(O) = \frac{1}{2}(\zeta^{\mu} - O^{\mu})^2$	?
Proceso de “aprendizaje” para ajustar los pesos	$w^{nuevo} = w^{anterior} + \Delta w$ $\Delta w = -\eta \frac{\partial E}{\partial w}$	?

? (quiero que se acerque a 1.0)



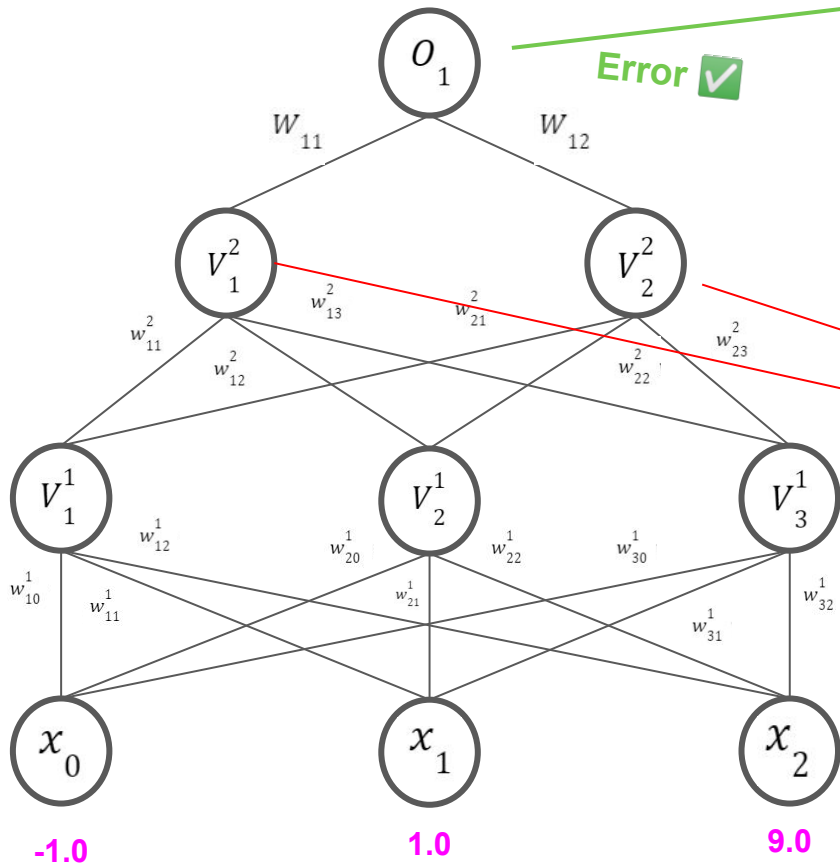
$$O_1 = \theta\left(\sum_{k=1}^2 V_k^2 \cdot W_{1k}\right)$$

$$E(O) = \frac{1}{2} \sum_i (\zeta^i - O_i)^2$$

	PERCEPTRÓN SIMPLE	PERCEPTRÓN MULTICAPA
Proceso para obtener la salida de la neurona (“predecir”)	$O = \theta\left(\sum_{i=0}^n x_i \cdot w_i\right)$	$V_j^m = \theta\left(\sum_{k=1} V_k^{m-1} \cdot w_{mk}\right)$ $m = 1 \dots M \quad (O_i = V_i^M, x_i = V_i^0)$
Función de error con respecto a la salida esperada	$E(O) = \frac{1}{2}(\zeta^\mu - O^\mu)^2$	$E(O) = \frac{1}{2} \sum_i (\zeta^\mu - O_i^\mu)^2$
Proceso de “aprendizaje” para ajustar los pesos	$w^{nuevo} = w^{anterior} + \Delta w$ $\Delta w = -\eta \frac{\partial E}{\partial w}$	?



? (quiero que se acerque a 1.0)




$$O_1 = \theta\left(\sum_{k=1}^2 V_k^2 \cdot W_{1k}\right)$$

$$E(O) = \frac{1}{2} \sum_i (\zeta^i - O_i)^2$$



Error ?

# RUMELHART, HINTON, WILLIAMS (1986)




- Trabajan en un nuevo algoritmo para actualizar los pesos de una red neuronal llamado **retropropagación** (*back-propagation*)
- Para calcular la actualización de los pesos utilizaremos el algoritmo del gradiente descendente y la regla de la cadena para la diferenciación.

# RETROPROPAGACIÓN: EXPLICACIÓN CONCEPTUAL




# RETROPROPAGACIÓN: EXPLICACIÓN CONCEPTUAL





Aplicamos la regla de la cadena:


$$\frac{\partial E}{\partial W_{11}} = \frac{\partial E}{\partial O_1} \frac{\partial O_1}{\partial h_1} \frac{\partial h_1}{\partial W_{11}}$$



# RETROPROPAGACIÓN: EXPLICACIÓN CONCEPTUAL




# RETROPROPAGACIÓN: EXPLICACIÓN CONCEPTUAL

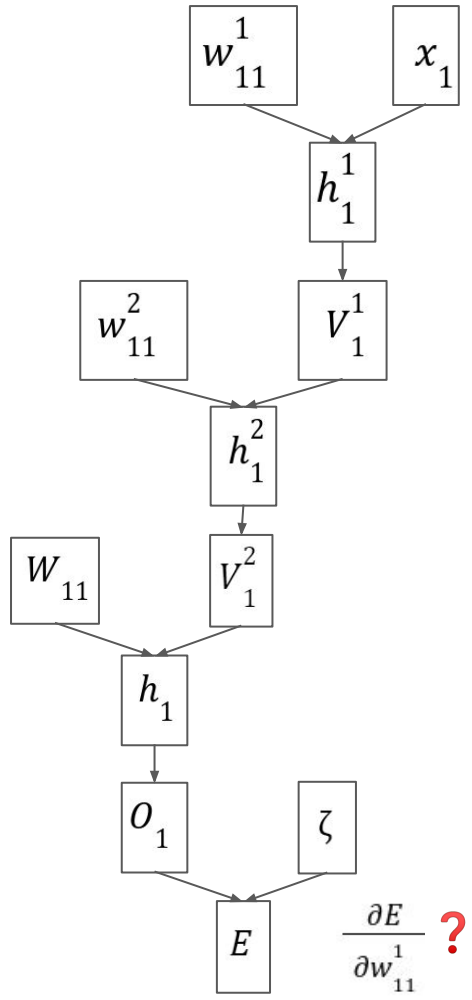



Aplicamos la regla de la cadena:


$$\frac{\partial E}{\partial w_{11}^2} = \frac{\partial E}{\partial O_1} \frac{\partial O_1}{\partial h_1} \frac{\partial h_1}{\partial V_1^2} \frac{\partial V_1^2}{\partial h_1^2} \frac{\partial h_1^2}{\partial w_{11}^2}$$



# RETROPROPAGACIÓN: EXPLICACIÓN CONCEPTUAL

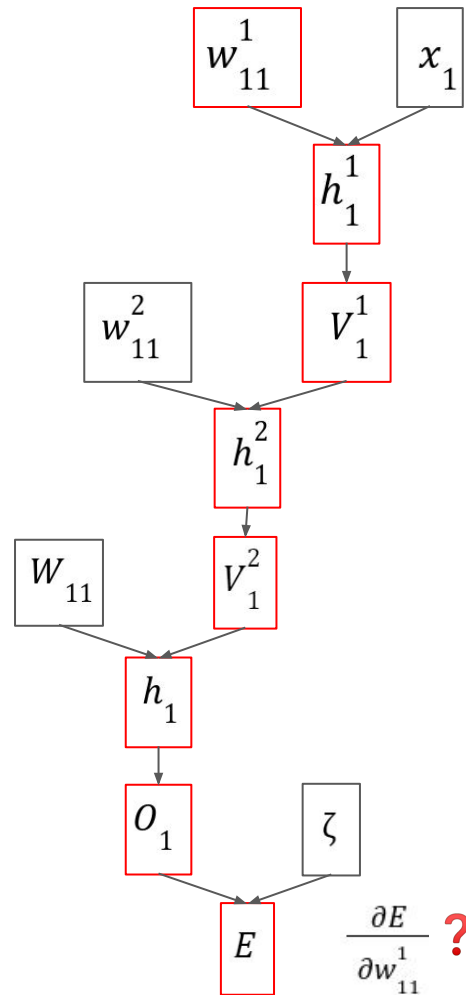


# RETROPROPAGACIÓN: EXPLICACIÓN CONCEPTUAL



Aplicamos la regla de la cadena:

$$\frac{\partial E}{\partial w_{11}^1} = \frac{\partial E}{\partial O_1} \frac{\partial O_1}{\partial h_1} \frac{\partial h_1}{\partial V_1^2} \frac{\partial V_1^2}{\partial h_1^2} \frac{\partial h_1^2}{\partial V_1^1} \frac{\partial V_1^1}{\partial h_1^1} \frac{\partial h_1^1}{\partial w_{11}^1}$$








# RETROPROPAGACIÓN: CAPA DE SALIDA

$$E(O) = \frac{1}{2} \sum_i (\zeta^u - o_i^u)^2$$

$$O_i = \theta(h_i)$$

$$h_i = \sum_{j=1} V_j^{M-1} \cdot W_{ij}$$




$$\Delta w = - \eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial W_{ij}} = \frac{\partial E}{\partial O_i} \frac{\partial O_i}{\partial h_i} \frac{\partial h_i}{\partial W_{ij}}$$

# RETROPROPAGACIÓN: CAPA DE SALIDA

$$E(O) = \frac{1}{2} \sum_i (\zeta^u - o_i^u)^2$$

$$O_i = \theta(h_i)$$

$$h_i = \sum_{j=1} V_j^{M-1} \cdot W_{ij}$$



$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial W_{ij}} = \left[ \frac{\partial E}{\partial O_i} \right] \left[ \frac{\partial O_i}{\partial h_i} \right] \left[ \frac{\partial h_i}{\partial W_{ij}} \right]$$


$$\frac{\partial E}{\partial W_{ij}} = (\zeta_i - O_i)(-1) \theta'(h_i)(1) V_j^{M-1}$$

# RETROPROPAGACIÓN: CAPA DE SALIDA

$$E(O) = \frac{1}{2} \sum_i (\zeta^u - o_i^u)^2$$

$$o_i = \theta(h_i)$$

$$h_i = \sum_{j=1} V_j^{M-1} \cdot W_{ij}$$



$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial W_{ij}} = \boxed{\frac{\partial E}{\partial o_i}} \boxed{\frac{\partial o_i}{\partial h_i}} \boxed{\frac{\partial h_i}{\partial W_{ij}}}$$

$$\frac{\partial E}{\partial W_{ij}} = (\zeta_i - o_i)(-1) \theta'(h_i)(1) V_j^{M-1}$$


$$\frac{\partial E}{\partial W_{ij}} = -\delta_i V_j^{M-1} \quad \delta_i = (\zeta_i - o_i) \theta'(h_i)$$

# RETROPROPAGACIÓN: CAPA DE SALIDA

$$E(O) = \frac{1}{2} \sum_i (\zeta^u - o_i^u)^2$$

$$o_i = \theta(h_i)$$

$$h_i = \sum_{j=1} V_j^{M-1} \cdot W_{ij}$$



$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial W_{ij}} = \boxed{\frac{\partial E}{\partial o_i}} \boxed{\frac{\partial o_i}{\partial h_i}} \boxed{\frac{\partial h_i}{\partial W_{ij}}}$$

$$\frac{\partial E}{\partial W_{ij}} = (\zeta_i - o_i)(-1) \theta'(h_i)(1) V_j^{M-1}$$

$$\frac{\partial E}{\partial W_{ij}} = -\delta_i V_j^{M-1} \quad \delta_i = (\zeta_i - o_i) \theta'(h_i)$$


$$\Delta W_{ij} = \eta \delta_i V_j^{M-1}$$

# RETROPROPAGACIÓN: CAPA DE SALIDA

$$E(O) = \frac{1}{2} \sum_i (\zeta^u - o_i^u)^2$$

$$o_i = \theta(h_i)$$

$$h_i = \sum_{j=1} V_j^{M-1} \cdot W_{ij}$$




$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial W_{ij}} = \boxed{\frac{\partial E}{\partial o_i}} \boxed{\frac{\partial o_i}{\partial h_i}} \boxed{\frac{\partial h_i}{\partial W_{ij}}}$$

$$\frac{\partial E}{\partial W_{ij}} = (\zeta_i - o_i)(-1) \theta'(h_i)(1) V_j^{M-1}$$

$$\frac{\partial E}{\partial W_{ij}} = -\delta_i V_j^{M-1} \quad \delta_i = (\zeta_i - o_i) \theta'(h_i)$$


$$\Delta W_{ij} = \eta \delta_i V_j^{M-1}$$

## RETROPROPAGACIÓN: CAPA OCULTA (M-1)



$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial w_{jk}^m} = \frac{\partial E}{\partial O} \frac{\partial O}{\partial h} \frac{\partial h}{\partial V_j^m} \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$

# RETROPROPAGACIÓN: CAPA OCULTA (M-1)



$$\Delta w = -\eta \frac{\partial E}{\partial w} \longrightarrow \frac{\partial E}{\partial w_{jk}^m} = \frac{\partial E}{\partial O} \frac{\partial O}{\partial h} \frac{\partial h}{\partial V_j^m} \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$

$$\frac{\partial E}{\partial w_{jk}^m} = (-1) \sum_i (\zeta_i - O_i) \theta'(h_i) (1) w_{ij} \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$


$$E(O) = \frac{1}{2} \sum_i (\zeta_i - O_i)^2$$

$$O_i = \theta(h_i)$$

$$h_i = \sum_{j=1} V_j^{M-1} \cdot W_{ij}$$



# RETROPROPAGACIÓN: CAPA OCULTA (M-1)



$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial w_{jk}^m} = \left[ \frac{\partial E}{\partial O} \right] \left[ \frac{\partial O}{\partial h} \right] \left[ \frac{\partial h}{\partial V_j^m} \right] \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$


$$\frac{\partial E}{\partial w_{jk}^m} = (-1) \sum_i \underbrace{(\zeta_i - O_i) \theta'(h_i)(1)}_{\delta_i} w_{ij} \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$

$$\frac{\partial E}{\partial w_{jk}^m} = - \sum_i \delta_i W_{ij} \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$

# RETROPROPAGACIÓN: CAPA OCULTA (M-1)

$$V_j^m = \theta(h_j^m)$$

$$h_j^m = \sum_{k=1} V_k^{m-1} \cdot w_{jk}^m$$



$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial w_{jk}^m} = \frac{\partial E}{\partial O} \frac{\partial O}{\partial h} \frac{\partial h}{\partial V_j^m} \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$


$$\frac{\partial E}{\partial w_{jk}^m} = - \sum_i \delta_i W_{ij} \left[ \frac{\partial V_j^m}{\partial h_j^m} \right] \left[ \frac{\partial h_j^m}{\partial w_{jk}^m} \right]$$

$$\frac{\partial E}{\partial w_{jk}^m} = - \sum_i \delta_i W_{ij} \theta'(h_j^m)(1) V_k^{m-1}$$

# RETROPROPAGACIÓN: CAPA OCULTA (M-1)

$$V_j^m = \theta(h_j^m)$$

$$h_j^m = \sum_{k=1} V_k^{m-1} \cdot w_{jk}^m$$



$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial w_{jk}^m} = \frac{\partial E}{\partial O} \frac{\partial O}{\partial h} \frac{\partial h}{\partial V_j^m} \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$


$$\frac{\partial E}{\partial w_{jk}^m} = - \sum_i \delta_i W_{ij} \left[ \frac{\partial V_j^m}{\partial h_j^m} \right] \left[ \frac{\partial h_j^m}{\partial w_{jk}^m} \right]$$

$$\frac{\partial E}{\partial w_{jk}^m} = - \sum_i \delta_i W_{ij} \theta'(h_j^m)(1) V_k^{m-1}$$

# RETROPROPAGACIÓN: CAPA OCULTA (M-1)

$$V_j^m = \theta(h_j^m)$$

$$h_j^m = \sum_{k=1} V_k^{m-1} \cdot w_{jk}^m$$



$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial w_{jk}^m} = \frac{\partial E}{\partial O} \frac{\partial O}{\partial h} \frac{\partial h}{\partial V_j^m} \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$

$$\frac{\partial E}{\partial w_{jk}^m} = - \sum_i \delta_i W_{ij} \left[ \frac{\partial V_j^m}{\partial h_j^m} \right] \left[ \frac{\partial h_j^m}{\partial w_{jk}^m} \right]$$


$$\frac{\partial E}{\partial w_{jk}^m} = - \underbrace{\sum_i \delta_i W_{ij} \theta'(h_j^m)(1)}_{\delta_j^m} V_k^{m-1}$$

$$\Delta w = \eta \delta_j^m V_k^{m-1}$$

# RETROPROPAGACIÓN: CAPA OCULTA (M-1)

$$V_j^m = \theta(h_j^m)$$

$$h_j^m = \sum_{k=1} V_k^{m-1} \cdot w_{jk}^m$$



$$\Delta w = -\eta \left[ \frac{\partial E}{\partial w} \right] \longrightarrow \frac{\partial E}{\partial w_{jk}^m} = \frac{\partial E}{\partial O} \frac{\partial O}{\partial h} \frac{\partial h}{\partial V_j^m} \frac{\partial V_j^m}{\partial h_j^m} \frac{\partial h_j^m}{\partial w_{jk}^m}$$

$$\frac{\partial E}{\partial w_{jk}^m} = - \sum_i \delta_i W_{ij} \left[ \frac{\partial V_j^m}{\partial h_j^m} \right] \left[ \frac{\partial h_j^m}{\partial w_{jk}^m} \right]$$

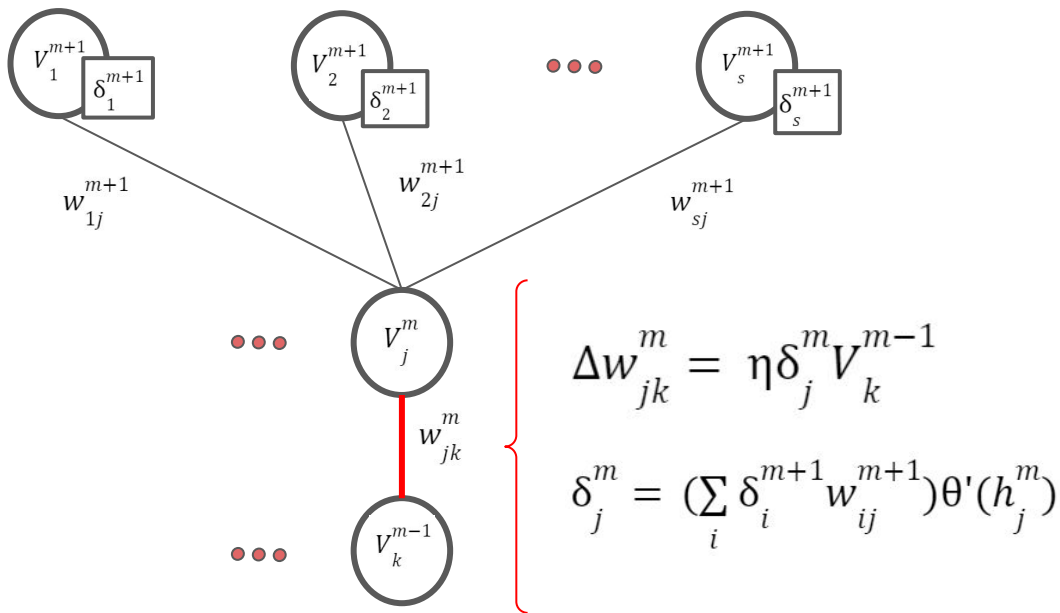
$$\frac{\partial E}{\partial w_{jk}^m} = - \underbrace{\sum_i \delta_i W_{ij} \theta'(h_j^m)(1)}_{\delta_j^m} V_k^{m-1}$$

$$\Delta w = \eta \delta_j^m V_k^{m-1}$$

# RETROPROPAGACIÓN: CAPA OCULTA

$$V_j^m = \theta(h_j^m)$$

$$h_j^m = \sum_{k=1} V_k^{m-1} \cdot w_{jk}^m$$



	PERCEPTRÓN SIMPLE	PERCEPTRÓN MULTICAPA
Proceso para obtener la salida de la neurona (“predecir”)	$O = \theta\left(\sum_{i=0}^n x_i \cdot w_i\right)$	$V_j^m = \theta\left(\sum_{k=1} V_k^{m-1} \cdot w_{mk}\right)$ $m = 1 \dots M \quad (O_i = V_i^M, x_i = V_i^0)$
Función de error con respecto a la salida esperada	$E(O) = \frac{1}{2}(\zeta^\mu - O^\mu)^2$	$E(O) = \frac{1}{2} \sum_i (\zeta^\mu - O_i^\mu)^2$
Proceso de “aprendizaje” para ajustar los pesos	$w^{nuevo} = w^{anterior} + \Delta w$ $\Delta w = - \eta \frac{\partial E}{\partial w}$	$\Delta W_{ij} = \eta \delta_i V_j \quad \delta_i = (\zeta_i - O_i) \theta'(h_i)$ $\Delta w_{jk}^m = \eta \delta_j^m V_k^{m-1} \quad \delta_j^m = \left(\sum_i \delta_i^{m+1} w_{ij}^{m+1}\right) \theta'(h_j^m)$





# ALGORITMO DEL PERCEPTRÓN MULTICAPA

1. Definir la arquitectura del perceptrón multicapa
  - a. Capas y cantidad de neuronas (*no tenemos un método para conseguir la ideal*)
  - b. Funciones de activación (*puede ser la misma para todas las neuronas o no*)
2. Inicializar los pesos sinápticos en valores aleatorios pequeños o cero
3. Definir: método de optimización, tasa de aprendizaje, épocas.
4. Para cada elemento del conjunto de datos
  - a. Calcular la salida de la neurona (*feedforward*)
  - b. Actualizar los pesos sinápticos (*backpropagation*)
5. Calcular el error del perceptrón para verificar si se alcanzó convergencia (MSE)
  - a. Si el perceptrón alcanzó convergencia, finalizar.
6. Repetir 3 y 4 hasta alcanzar convergencia o hasta finalizar la cantidad de épocas

# ALGORITMO DEL PERCEPTRÓN MULTICAPA

Para cada elemento del conjunto de datos

- a. Calcular la salida de la neurona (*feedforward*) (**M** es la cantidad de capas)

$$V^0 = x^\mu$$

$$V_j^m = \theta \left( \sum_{k=1} V_k^{m-1} \cdot w_{mk} \right) \quad m = 1 \dots M - 1$$

$$O_i = \theta \left( \sum_j V_j^{M-1} w_{ij} \right)$$

# ALGORITMO DEL PERCEPTRÓN MULTICAPA

Para cada elemento del conjunto de datos

- b. Actualizar los pesos sinápticos (*backpropagation*)

Calculamos los deltas para cada capa

$$\delta_i = (\zeta_i - O_i)\theta'(h_i) \quad \text{capa salida}$$

$$\delta_j^m = (\sum_i \delta_i^{m+1} w_{ij}^{m+1})\theta'(h_j^m) \quad \text{capa oculta}$$

Calculamos la actualización correspondiente para los pesos

$$\Delta W_{ij} = \eta \delta_i V_j^{M-1} \quad \text{capa salida}$$

$$\Delta w_{jk}^m = \eta \delta_j^m V_k^{m-1} \quad \text{capa oculta}$$

## RESUMEN

- El perceptrón multicapa me permite modelar transformaciones complejas (expande el comportamiento de los perceptrones simples)
- La arquitectura del perceptrón multicapa debe realizarse manualmente. A priori, no tenemos una receta que nos permita definir “la mejor arquitectura”.
- El algoritmo de retropropagación provee un mecanismo para hallar las actualizaciones de los pesos que nos permiten minimizar la función de costo.

## ALGUNAS VARIACIONES POSIBLES

Variable	Posibles Valores
Función de activación ( $\theta$ )	Escalón, Identidad, Sigmoidea
Tasa de aprendizaje ( $\eta$ )	$\sim 0.1$
Actualización de los pesos	Batch/Online
Error del perceptrón (función de costo)	Accuracy, suma valores absolutos, MSE
Épocas	
Método de optimización	Gradiente Descendente
Parámetros de función de activación	$\theta$ de tanh o de log
Técnica para separar en entrenamiento y testeo	Ejemplo: 80%-20%
Arquitectura de la red	